

Modelos No Supervisados

Segmentacion de Perfiles Operacionales de Maquinaria Industrial

AI4I 2020 Predictive Maintenance Dataset

Equipo:

- Madheline Katerine Torres Hallo
- Carlos Vladimir Ramirez Espinoza
- Dennys Francisco Salazar Dominguez

Contenido

Estructura de la presentacion

- 01 Contexto y Dataset
- 02 Analisis Exploratorio
- 03 K-Means
- 04 DBSCAN
- 05 PCA y t-SNE
- 06 Comparacion de Modelos
- 07 Perfiles Operacionales
- 08 Deteccion de Anomalias
- 09 Conclusiones

Vision General del Proyecto

10K

Registros de sensores

Dataset AI4I 2020

5

Variables de sensores

Temperatura, velocidad, torque, desgaste

4

Algoritmos aplicados

K-Means, DBSCAN, PCA, t-SNE

2

Perfiles identificados

Regimenes operacionales

Objetivo: Identificar perfiles operacionales y detectar anomalias en maquinaria industrial mediante aprendizaje no supervisado.

Contexto y Dataset

Problema de negocio

- Plataforma IoT de monitoreo industrial requiere segmentar perfiles operacionales de sus activos.
- Reducir tiempos no planificados de parada mediante alertas tempranas diferenciadas.
- Adaptar umbrales de tolerancia segun el regimen de operacion identificado.

10,000

Registros totales

96.6%

Sin fallo

3.4%

Con fallo

3 tipos


L / M / H

Variables del dataset


Variable	Descripcion	Uso
Air temperature [K]	Temperatura del aire	Incluida
Process temperature [K]	Temperatura del proceso	Incluida
Rotational speed [rpm]	Velocidad rotacional	Incluida
Torque [Nm]	Torque del sistema	Incluida
Tool wear [min]	Desgaste de herramienta	Incluida
Machine failure	Fallo binario (0/1)	Validacion

Analisis Exploratorio del Dataset

Distribución de Variables — AI4I Predictive Maintenance



Matriz de Correlación — Variables Numéricas



Hallazgos clave

Temperatura

Distribucion normal ~300 K. Alta correlacion entre aire y proceso (+0.88).

Torque / Velocidad

Correlacion negativa muy fuerte (-0.88). Relacion mecanica dominante del sistema.

Desgaste

Distribucion uniforme (0-253 min). Predictor individual mas relevante de fallo.

Tipo de maquina

Matriz de correlacion — la relacion Torque/Velocidad y la interdependencia termica son los patrones dominantes. Predominio tipo L (61.1%). El tipo H muestra mayor variabilidad en desgaste.

Pipeline de Preparacion de Datos

1

Exclusion de UDI

Identificador sin valor predictivo. No aporta informacion al clustering.

2

Machine failure como referencia

Variable objetivo conservada solo para validacion. No incluida en entrenamiento.

3

Codificacion de Type

LabelEncoder: H=0, L=1, M=2. Para analisis complementario por tipo de maquina.

4

Analisis de outliers IQR

Cuantificacion de valores atipicos por variable. Sin casos criticos que requieran eliminacion.


5

StandardScaler

Escalado a media=0, std=1. Garantiza equidad entre variables en calculo de distancias euclídeas.

K-Means — Selección de K Optimo

Selección del Número Óptimo de Clusters — K-Means



El valor moderado del silhouette es inherente a datos de sensores industriales continuos — las fronteras entre regimenes operacionales son físicamente graduales, no discretas.

Metodo de seleccion

Metodo del Codo

Mayor reduccion de inercia en K=1 a K=2. Curva se aplanan progresivamente.


Silhouette Score

Maximizado en K=2 con valor de 0.2109. Umbrales 0.25 y 0.50 marcados.

K = 2

K optimo seleccionado | Silhouette: 0.2109

K-Means — Segmentacion y Analisis Silhouette



Perfiles identificados

C0 Regimen Caliente

4,955 maquinas (49.6%)

Temp. proceso: 311.8 K


Tasa de fallo: 3.3%

C1 Regimen Estandar

5,045 maquinas (50.5%)


Temp. proceso: 308.3 K

Tasa de fallo: 3.4%




DBSCAN — Clustering Basado en Densidad

Selección de eps — K-Distance Graph



Resultado de segmentación



Parametros y resultados

eps = 0.8

Determinado por K-Distance Graph

min_samples = 5

Heurística para baja dimension

2

Clusters

261


Puntos de ruido

0.3197

Los 261 puntos de ruido representan condiciones operacionales atípicas. Su tasa de fallo supera significativamente la media global — validación real de relevancia operacional.

PCA — Reduccion de Dimensionalidad

Análisis PCA — Reducción a 2 Componentes Principales



Interpretacion de componentes

PC1 38.0%

Relacion inversa torque-velocidad. Loadings opuestos en ambas variables.

PC2 20.4%

Variacion termica del sistema. Loadings positivos en ambas temperaturas.



58.4%

Varianza acumulada con 2 componentes

Para analisis exhaustivo se recomiendan 4 componentes (~80% varianza).

t-SNE — Visualización No Lineal

Visualización t-SNE (perplexity=30, lr=200, max_iter=1000)



Panel 1: Clusters K-Means

Separación de los dos grupos en el espacio no lineal.
Confirma la segmentación térmica.


Panel 2: Gradiente de Torque

Distribución continua del torque. Zonas de alto torque
concentradas en regiones específicas.

Panel 3: Fallos Reales

Los fallos NO se distribuyen aleatoriamente — se
concentran en zonas específicas. Validación clave de los
perfiles.

Comparacion de Algoritmos de Clustering




DBSCAN supera a K-Means en silhouette (0.3197 vs 0.2109) y adicionalmente detecta 261 condiciones operacionales anomalas validadas contra Machine failure.

Ambos algoritmos son complementarios: K-Means para segmentacion interpretable, DBSCAN para deteccion robusta de anomalias.

Criterio	K-Means	DBSCAN
Silhouette Score	0.2109	0.3197
Clusters	2	2
Outliers detectados	0	261
Detecta ruido	No	Si
Forma clusters	Esferica	Arbitraria
Robustez al ruido	Baja	Alta
Interpretabilidad	Alta	Media
Uso recomendado	Segmentacion	Anomalias

Perfiles Operacionales Identificados





C0 — Regimen Caliente	
Maquinas	4,955 (49.6%)
Temp. proceso	311.8 K
Torque medio	39.8 Nm
Desgaste	126.8 min
Tasa de fallo	3.3%

C1 — Regimen Estandar	
Maquinas	5,045 (50.5%)
Temp. proceso	308.3 K

Diferencia principal: perfil termico (~3 K en temperatura de proceso). Tasas de fallo similares indican que la temperatura sola no determina el riesgo — el desgaste de herramienta y condiciones de torque extremo actuan como factores complementarios.

Deteccion de Anomalias — Isolation Forest vs LOF

Detección de Anomalías — Comparación Isolation Forest vs LOF



Isolation Forest

n_estimators=200 | contamination=0.05

500 anomalias detectadas (5.0%)

Local Outlier Factor

n_neighbors=20 | contamination=0.05

500 anomalias detectadas (5.0%)

Consenso (ambos)


Interseccion de ambos metodos

Subconjunto de maxima confianza

Validacion: Los puntos anomalos presentan una tasa de fallo real varias veces superior a la media global — confirma relevancia operacional, no solo ruido estadistico.

Pipeline Completo del Proyecto

Pipeline Completo — Modelos No Supervisados (AI4I Predictive Maintenance)



0.2109

K-Means Silhouette

K = 2

0.3197

DBSCAN Silhouette

eps=0.8, ms=5

58.4%

Varianza PCA

2 componentes

261

Outliers detectados

2.6% del total

El pipeline es reproducible: todas las rutas se detectan automáticamente desde cualquier entorno de ejecución (VS Code, Jupyter Lab, terminal).

Conclusiones y Recomendaciones

1. Perfiles identificados

Se identificaron 2 regimenes operacionales diferenciados por temperatura de proceso (~ 3 K). Tasas de fallo similares confirman que el riesgo es multivariable.

2. DBSCAN supera a K-Means

Silhouette 0.3197 vs 0.2109. DBSCAN detecta adicionalmente 261 anomalias operacionales con relevancia real validada.

3. PCA y t-SNE son complementarios

PCA para interpretacion de variables dominantes (58.4% varianza). t-SNE revela sub-estructuras no lineales y concentracion de fallos por zona.

4. Propuestas de mejora

Integracion SCADA para alertas en tiempo real. Modelos supervisados con clusters como features. Clustering jerarquico para mayor granularidad.

Gracias

Modelos No Supervisados — AI4I Predictive Maintenance

UEES — Maestria en Inteligencia Artificial | Aprendizaje Automatico

Equipo:

Madheline Katerine Torres Hallo

Carlos Vladimir Ramirez Espinoza

Dennys Francisco Salazar Dominguez

Repositorio: github.com/dfsd0001/TrabajoGrupal-S3